Аналіз та візуалізація даних результатів досліджень

Аналіз даних

Аналіз даних отримує інформацію з даних, щоб описати або пояснити якесь досліджуване явище. Необроблені дані не говорять самі за себе; їх потрібно підготувати, інтерпретувати, проаналізувати та представити, перш ніж з них можна буде зробити будь-які висновки. Таким чином, досліднику потрібно перетворити великі обсяги даних на керовану та значущу інформацію.

Два основних види аналізу даних - це кількісний та якісний аналіз. Ці терміни використовуються в різних сенсах соціальних наук. У вузькому сенс полягає в тому, що кількісний аналіз даних працює на кількісних даних (числах), тоді як якісний аналіз даних працює на якісних даних (слова, зображення, відеокліпи тощо). У більш широкому сенсі кількісне дослідження та якісне дослідження є двома дослідницькими парадигмами.

Кількісний аналіз даних

Анкети та спостереження, як правило, виробляють великий обсяг кількісних даних. Однак будь-який метод збору даних може генерувати кількісні дані. Навіть якщо згенеровано вихідні дані мають форму тексту або зображень, їх можна класифікувати та закодувати, щоб отримати цифри, які потім можна кількісно проаналізувати.

Види кількісних даних

Існують різні види кількісних даних, які відрізняються з точки зору того, як ними можна маніпулювати математично:

- **Номінальні дані.** Номінальні дані (також звані категоричними даними) позначають категорії і не мають числового значення, на якому можна виконувати арифметичні операції. Наприклад, для того, щоб представити сімейний стан, "1" може означати самотній, "2" одружений, а "3" співжиття. Не має сенсу проводити обчислення, такі як середнє значення або медіана на цих даних, і їх не можна упорядкувати. Їх можна використовувати лише для представлення частот.

- **Ординальні дані.** Ординальні дані (також звані ранжованими даними) також позначають категорії, але ці категорії можуть бути ранжовані, тобто між ними є порядок. Прикладом можуть бути наступні значення, які можна використовувати для класифікації відповідей про привабливість продукту (1¼ повністю не подобається, 2¼ не подобається, 3¼ ні подобається, ні не подобається, 4¼ подобається, 5¼ повністю подобається). Ці значення можна ранжувати, і має сенс сказати, що 5 вище 4, що, в свою чергу, вище 3. Однак немає сенсу говорити, що 4 вдвічі вище 2.

- **Інтервальні дані.** Інтервальні дані впорядковані так само, як і порядкові дані, а відстань між двома сусідніми точками на шкалі завжди однакова. Це робить значущим використання додавання та віднімання на цьому виді даних. Прикладом інтервальних даних є календарні роки, де різниця між 2014 і 2010 роками така ж, як і різниця між 2010 і 2006 роками.
- **Дані співвідношення**. Дані співвідношення схожі на інтервальні дані, і, крім того, масштаб має нуль. Типовими прикладами є вік, зріст та дохід. Для даних про співвідношення значущими є всі види арифметичних операцій. Наприклад, має сенс сказати, що людина, яка заробляє 4000 євро, заробляє вдвічі більше, ніж людина, яка заробляє 2000 євро.

Описова статистика

Описова статистика використовується для кількісного опису вибірки даних. Описова статистика відрізняється від інференційної статистики, оскільки вона має на меті лише описати дану вибірку даних, тоді як інференційна статистика використовується для того, щоб зробити висновки про популяцію, яку представляє вибірка. Основною формою описової статистики є відображення частин вибірки даних через таблиці або діаграми. Таблиці дозволяють відображати дуже детальні дані, але вони можуть бути обтяжливими для читача, тоді як діаграми можуть бути більш візуально привабливими. Деякі поширені типи діаграм: гістограми, які часто використовуються для відображення частот; кругові діаграми, які корисні для відображення пропорцій; і лінійні графіки, які можуть показувати тенденції в даних.

Зразки даних також можуть бути описані за допомогою різних сукупних заходів:

• **Середнє значення.** Для вибірки даних середнє значення (або середнє) - це сума значень, поділених на кількість значень. Наприклад, середнє значення {2, 4, 8, 15, 16, 16, 100} становить 23. Як видно з цього прикладу, на середнє значення можуть сильно впливати значення відхилів.

• **Медіана.** Медіана - це значення, яке відокремлює вищу половину вибірки даних від нижньої половини. Для наведеного вище прикладу медіана становить 15. На медіану менше впливають значення відхидів, ніж на середнє значення.

• **Опція (Mode)**. Опція - це значення, яке найчастіше з'являється у зразку даних. Для наведеного вище прикладу режим - 16.

• **Діапазон**. Діапазон вибірки даних - це різниця між його найвищим і найнижчим значенням. Для наведеного вище прикладу діапазон становить 98. Що стосується середнього значення, то діапазон дуже чутливий до значень викідних значень (outlier values).

• **Стандартне відхилення.** Стандартне відхилення вибірки даних визначає середню величину мінливості. Це обчислюється шляхом взяття квадратного кореня середнього квадратичних відмінностей значень від їх середнього значення (

$$\sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{N}}$$

σ = среднеквадратическое отклонение
N = размер выборки
x_i = каждый элемент выборки

.

Таблиці, діаграми та агрегатні виміри є цінними для опису зразка даних, і вони зазвичай використовуються в комбінації.

Інференційна статистика

Інференційна статистика спрямована на досягнення висновків, які виходять за рамки однієї вибірки даних, наприклад, чи існує зв'язок між двома змінними або чи існує різниця між двома популяціями. Таким чином, інференційна статистика використовується для висновків зі зібраних даних до більш загальних умов.

Часто цікаво дослідити, чи існує зв'язок між двома змінними, наприклад, якщо дохід і рівень освіти пов'язані один з одним. Поширеною технікою визначення міцності зв'язку між двома змінними є обчислення коефіцієнта кореляції. Коефіцієнт кореляції - це значення від -1 до +1, при якому позитивне (негативне) значення означає, що між двома змінними існує позитивний (негативний) зв'язок, а значення, близьке до +1 або -1, означає, що існує сильна кореляція, тоді як 0 означає відсутність кореляції. Однак, навіть якщо існує сильна кореляція між двома змінними у виборці даних, це не означає, що існує будь-яка кореляція між змінними в популяції, з якої була взята вибірка; можливо, вибірка була нерепрезентативною, тому очевидний зв'язок був просто випадковим. Для того, щоб визначити, чи пов'язані дві змінні на значному рівні, були розроблені різні статистичні методи, одним з яких є тест хі-квадрат (chi-square).

Інше питання, яке часто виникає, полягає в тому, чи є якась значна різниця між двома популяціями, наприклад, чи люди на певній дієті здоровіші за інших. При порівнянні зразків з двох популяцій існує ризик того, що різниця між ними обумовлена випадковістю. Для того, щоб з'ясувати, чи можна узагальнити виявлені відмінності у зразках для популяцій, існують тести, такі як t-тест.

Якісний аналіз даних

Якісний аналіз даних працює над якісними даними, включаючи текст, звук, фотографії, зображення та відеокліпи. У той час як кількісні дані вимірюють явища, якісні дані описують їх. Велика кількість якісних даних може бути отримана шляхом неструктурованих інтерв'ю, але будь-який метод збору даних може бути використаний для отримання якісних даних. Наприклад, анкета з відкритими питаннями призведе до тексту, який потрібно проаналізувати.

Деякі загальні характеристики якісного аналізу даних такі:

- **Ітеративні.** Збір та аналіз даних, як правило, відбуваються паралельно та ітеративно, де результати аналізу даних впливають на те, як відбувається збір даних.
- **Індуктивний.** Аналіз переходить від конкретного до загального, тобто на основі аналізу конкретних випадків і ситуацій пропонуються більш загальні твердження.
- **Орієнтований на дослідника.** Передумови, цінності та досвід дослідника є важливими факторами, які впливають на аналіз даних.

Існують різні підходи до якісного аналізу даних; три з основних - це контент-аналіз, обґрунтована теорія та аналіз дискурсу.

Контент-аналіз

Контент-аналіз використовується для кількісної оцінки вмісту тексту або інших якісних даних. Ідея полягає в тому, щоб класифікувати елементи тексту за категоріями, а потім обчислити частоти елементів у кожній категорії. Контент-аналіз проводиться в шести видах діяльності:

1. Виберіть зразок текстів. Критерій включення текстів до зразка повинен бути чітким.

2. Розбийте тексти на одиниці. Одиницями можуть бути окремі слова, речення або навіть цілі абзаци.

3. Розробити категорії для аналізу. Категорії повинні бути обрані таким чином, щоб вони були актуальними для розглянутого дослідницького питання. Наприклад, якщо питання дослідження стосується дослідження основних тем у виступах американських політиків, можливі категорії включають реформу охорони здоров'я, Росію, тероризм, чаювання та безробіття.

4. Кодуйте одиниці відповідно до категорій. Одиниці, визначені в діяльності 2, кодуються з використанням категорій з діяльності 3, тобто кожна одиниця віднесена до однієї або декількох категорій.

5. Підрахуйте частоту одиниць для кожної категорії. Для кожної категорії розраховується кількість одиниць.

6. Аналізуйте тексти з точки зору частот. Вивчіть та порівняйте частоти з вправи 5 для подальшого аналізу текстів. Наприклад, можна дослідити тенденції, що представляють інтерес для різних політичних тем.

Однією з сильних сторін контент-аналізу є те, що процес зрозумілий і простий, а це означає, що надійність буде високою, тобто різні дослідники прийдуть по суті до однакових результатів.

Слабкість підходу полягає в тому, що він досить нечутливий до контексту, оскільки аналізуються лише окремі одиниці. Відносини підрозділів тексту та наміри письменника не враховуються. Таким чином, контент-аналіз в першу чергу корисний для вивчення досить нескладних аспектів тексту.

Обґрунтована теорія (Grounded Theory)

Обґрунтована теорія - це дослідницька стратегія, яка прагне розробити теорії шляхом аналізу емпіричних даних. На відміну від експериментів, обґрунтована теорія починається не з гіпотези, яку потрібно перевірити, а з даних, з яких можна створити теорію. Обґрунтована теорія також відрізняється від дослідницьких стратегій, таких як етнографія, які задовольняються наданням багатих описів конкретних ситуацій, але без теорій. Обґрунтована теорія кидає виклик підходу до теоретизації зверху вниз, в якому дослідник спочатку розробляє теорію, а потім перевіряє, чи відповідає вона емпіричним даним. Натомість обґрунтована теорія наполягає на тому, що емпіричні дані є відправною точкою, на якій слід будувати теорії. Теорія з'являється через аналіз і ґрунтується на даних.

Обґрунтована теорія може бути використана не тільки як дослідницька стратегія, а також як метод якісного аналізу даних. Принципи кодування будуть однаковими, коли обґрунтована теорія використовується для аналізу даних. Під час відкритого кодування дослідник класифікує одиниці тексту, якими можуть бути слова, речення або абзаци. Потім коди класифікуються та пов'язані один з одним в осьовому кодуванні. Під час вибіркового кодування визначаються найважливіші коди та категорії, а також зв'язки між ними. Ключова відмінність від контент-аналізу полягає в тому, що в обґрунтованій теорії коди не даються заздалегідь, а виникають поступово з роботи дослідника з текстом. Коди не базуються на якійсь вже існуючій теорії, але замість цього дослідник зберігає відкритий розум і дозволяє тексту забезпечити основу для прийняття рішення, які коди включити.

Аналіз дискурсу

Ди́скурс (від фр. discours — промова, розмова на тему чогось) — **єдність мовлення та ситуації, в якій воно відбувається**.

У той час як контент-аналіз зосереджується на тому, що прямо зазначено в тексті, аналіз дискурсу «копається» в його неявних і прихованих значеннях. Відправною точкою аналізу дискурсу є те, що сенс тексту не лежить на поверхні. Слова в тексті не можна сприймати номінально. Натомість їх можна зрозуміти лише в більш широкому контексті, який включає письменника, наміри та основні припущення, які приймаються як належне. Дослідники повинні враховувати цей контекст при аналізі тексту, і, зокрема, вони повинні розуміти мету письменника, тобто яких ефектів він хотів досягти.

У аналізі дискурсу текст ніколи не є лише об'єктивним представленням існуючого світу. Натомість текст сприяє створенню та підтримці світу. Завдання дослідника полягає в тому, щоб деконструювати текст, розкрити його приховані значення, пояснити, як він створює світ, і показати, які культурні повідомлення він передає та зміцнює. У той час як обґрунтована теорія вимагає від дослідника підходу до даних з відкритим розумом і без будь-яких теоретичних припущень, аналіз дискурсу заохочує дослідника використовувати концепції та теорії, які можуть допомогти "заповнити прогалини" в тексті. Оскільки аналіз дискурсу має на меті з'ясувати, що мається на увазі в тексті, існує потреба в теорії, яка може функціонувати як пара окулярів, щоб підтримати дослідника у відкритті прихованих значень тексту.

Аналіз дискурсу часто критикують за те, що він дуже суб'єктивний, тобто залежить від компетентності, розуміння та теоретичної позиції окремого дослідника. Цю суб'єктивність можна прийняти або пом'якшити, якщо дослідник зробить свої міркування простежуваними, зробивши свої передумови та теоретичні припущення явними.

Зв'язок стратегій дослідження та методів дослідження

Зв'язок між стратегіями дослідження, методами збору даних та методами аналізу даних показані на рис.

По-перше, дослідник обере одну або кілька дослідницьких стратегій, які будуть застосовані. Для кожної дослідницької стратегії він вибере один або кілька методів збору даних для використання, а також один або кілька методів аналізу даних. На практиці ці рішення можуть бути не такими послідовними, як запропоновано тут, а замість цього будуть розвиватися в ітераціях протягом усього дослідницького проєкту.

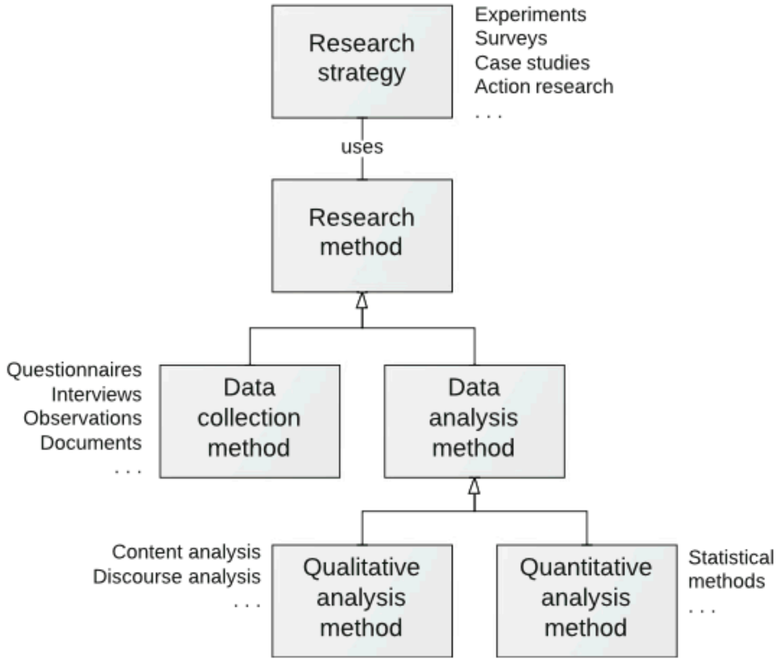

Конкретним прикладом може бути дослідник, який має намір розробити метод розробки моделей бізнес-процесів. Мета тут - розробити артефакт (метод). Щоб зібрати вимоги до методу, дослідник вибирає опитування як одну з дослідницьких стратегій у проекті та намагається отримати пропозиції для вимог від експертів з управління бізнес-процесами. Для збору інформації від експертів він вирішує використовувати інтерв'ю (метод збору даних) та аналізувати зібрані дані інтерв'ю за допомогою контент-аналізу (якісний метод). На додаток до вимог, він також вирішує оцінити метод. З цією метою вибирається експеримент як стратегія дослідження, і встановлюється ситуація, в якій студенти, а також досвідчені розробники процесів повинні використовувати метод. Він спостерігає (метод збору даних) за поведінкою цих людей при використанні методу і реєструє їх результати (інший метод збору даних), який пізніше аналізується за допомогою статистичних (кількісних) методів.

Візуалізація даних

Згруповані жердини (Bar) або стовпчікова діаграма

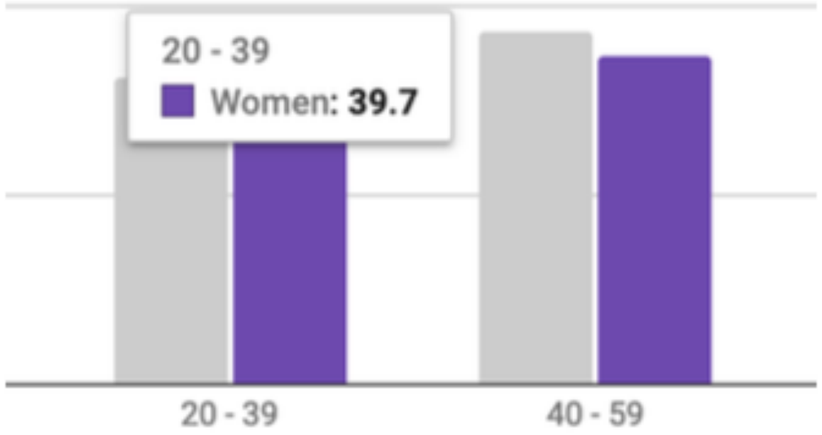

Найкраще порівнювати категорії пліч-о-пліч. Якщо мітки довгі, використовуйте горизонтальні смуги замість вертикальних стовпців.

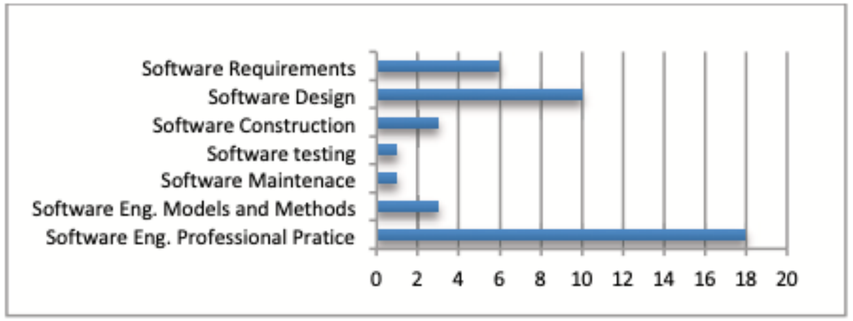

Найкраще порівнювати категорії в окремих кластерах. Якщо мітки довгі, використовуйте горизонтальні смуги замість вертикальних стовпців.

Стек жердин або стовпчастий графік

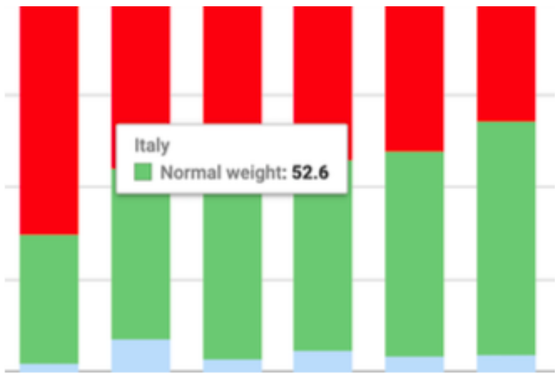

Найкраще порівняти підкатегорії або частини цілого. Якщо мітки довгі, використовуйте горизонтальні смуги замість вертикальних стовпців.

Гістограма

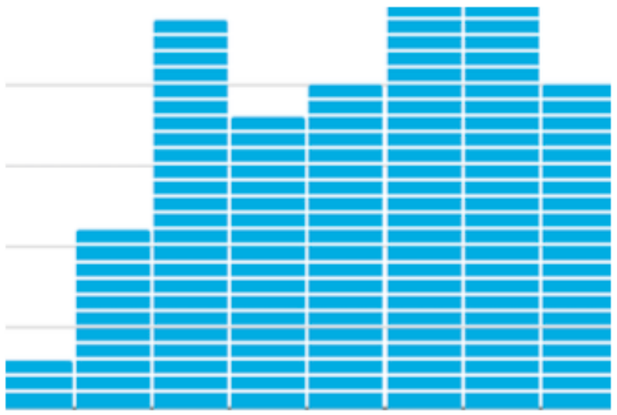

Найкраще показати розподіл необроблених даних з кількістю значень у кожному сегменті.

Кругова діаграма

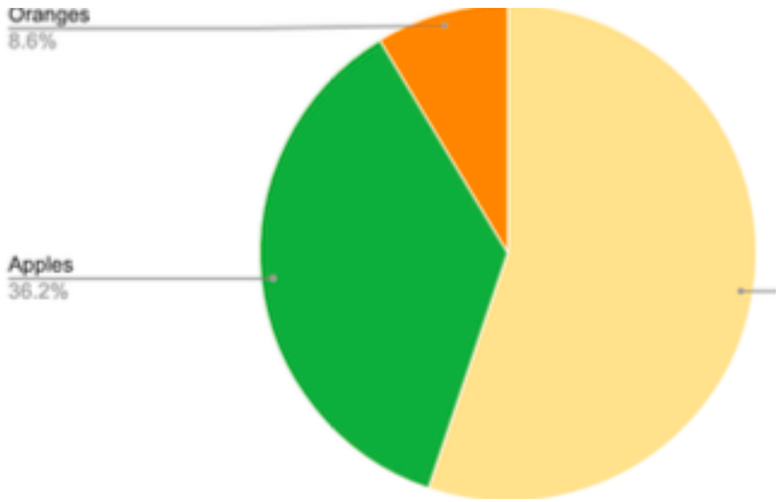

Найкраще показати частини цілого, але важко оцінити розмір скибочок.

Лінійна діаграма

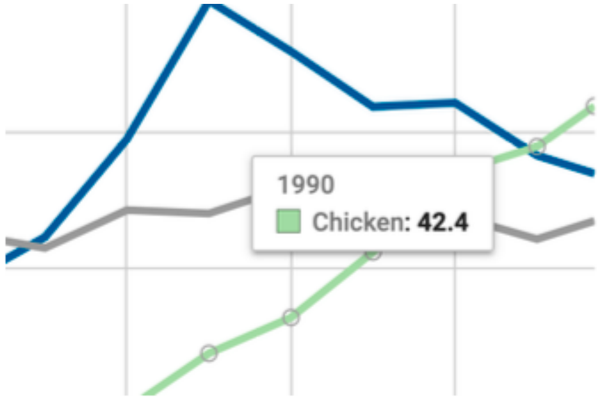

Найкраще показувати безперервні дані, такі як зміна з часом.

Анотована лінійна діаграма

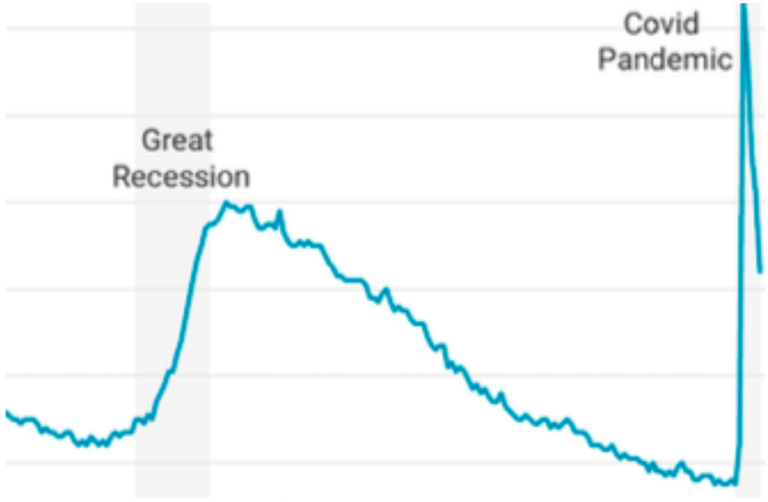

Найкраще додавати нотатки або виділяти дані всередині діаграми, такі як історичний контекст на лінійній діаграмі.

Відфільтрована лінійна діаграма

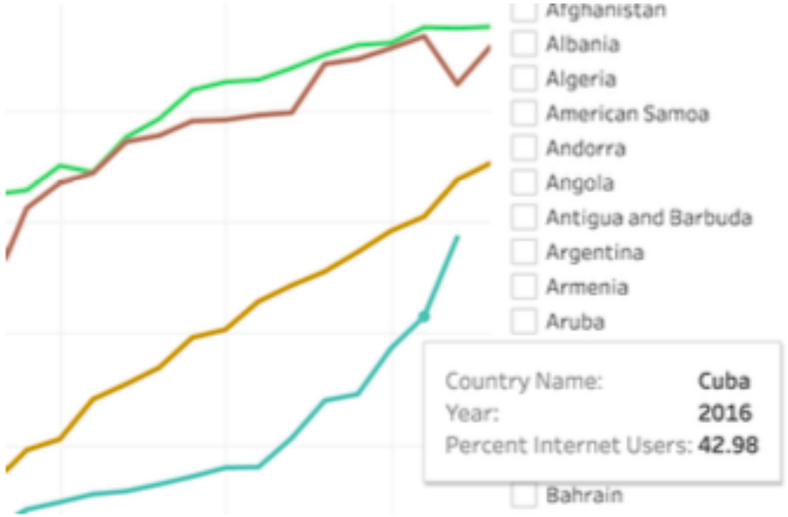

Найкраще показувати кілька рядків безперервних даних, які користувачі можуть вмикати та вимикати.

Діаграма складеної площі (Stacked area chart)

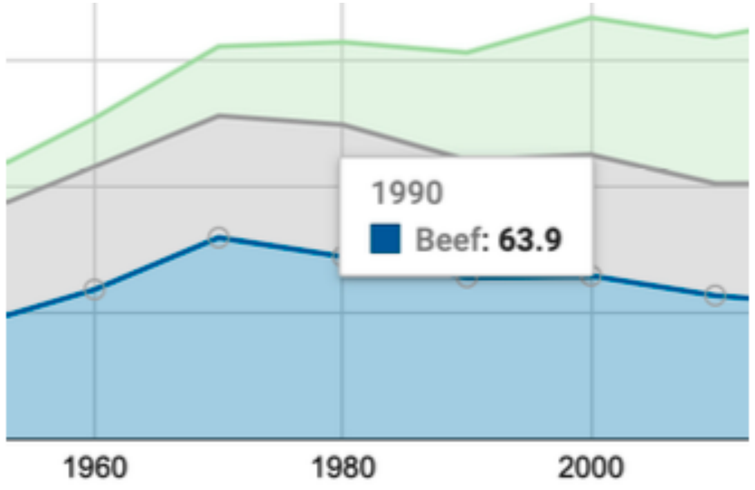

Найкраще показати частини цілого, з безперервними даними, такими як зміна з часом.

Діаграма діапазону

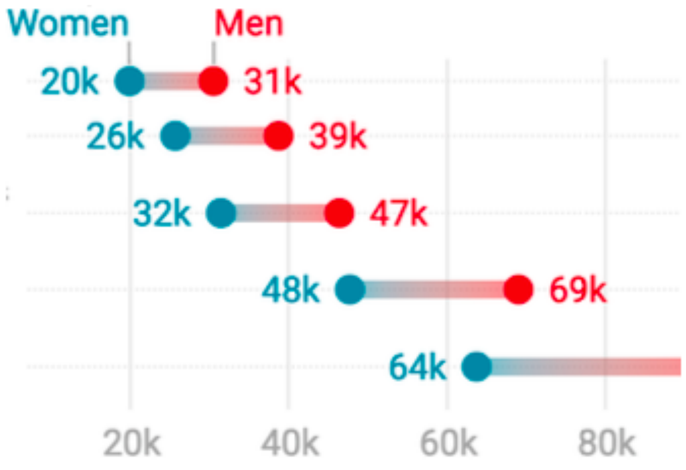

Найкраще показати прогалини між точками даних, такі як нерівності.

Діаграма розсію (Scatter chart)

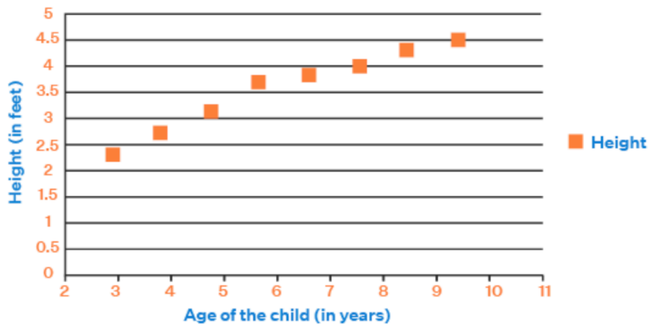

Найкраще показати взаємозв'язок між двома змінними, причому кожна крапка представляє свої координати X і Y.

Бульбашкова діаграма

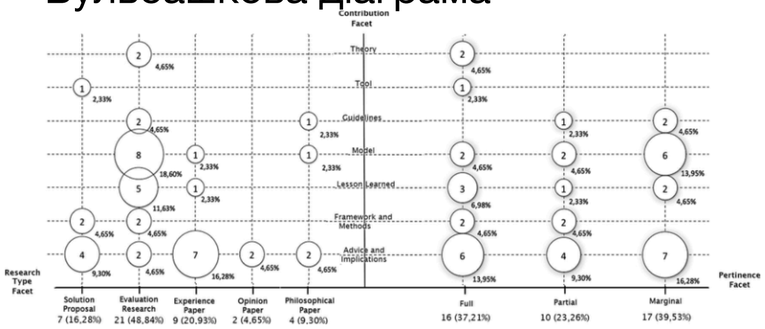

Найкраще показати взаємозв'язок між трьома або чотирма наборами даних з координатами XY, розміром бульбашки та кольором.

Блискучі лінії (Sparklines)

Індекс	День	Значення	Зміна
Dow Jones		10765.45	–32.82 (–0.30 %)
S&P 500		1256.92	–8.10 (–0.64 %)

Спарклайни показують рух Промислового індексу Доу-Джонса та S&P 500 протягом 7 лютого 2006 року

Спарклайн — дуже маленька лінійна діаграма, зазвичай намальована без осей чи координат. Вона представляє загальну форму коливання (переважно у часі) певної міри